

Trabalho Final - Predição de Diabetes (Pima Indians)

Integrantes

Pedro Henrique da Silva - RA: 23021607-2

Victor Hugo Rodrigues de Oliveira - RA: 23418156-2

Victor Hundo Silva Garcia - RA: 23030968-2

Contextualização

O diabetes mellitus é uma doença crônica que afeta milhões de pessoas no mundo. A detecção precoce é fundamental para reduzir complicações e melhorar a qualidade de vida dos pacientes. Com o avanço da Inteligência Artificial, modelos de aprendizado de máquina podem apoiar a identificação de padrões em dados clínicos e auxiliar profissionais de saúde na triagem de risco.

Problema investigado

Este trabalho investiga se é possível prever a presença de diabetes em pacientes da etnia Pima Indians com base em variáveis clínicas e demográficas, como glicose, pressão arterial, IMC e idade.

Hipótese

Modelos de classificação supervisionada conseguem distinguir pacientes com e sem diabetes a partir dos atributos disponíveis. Espera-se que o SVM apresente bom desempenho após a padronização dos dados, enquanto o KNN pode ser sensível à escolha do número de vizinhos e à distribuição das classes.

Dataset utilizado

Item	Descrição
Nome	Pima Indians Diabetes Database
Origem	Kaggle / UCI Machine Learning Repository
Registros	768 amostras
Atributos	8 variáveis numéricas
Variável alvo	Outcome (0 = sem diabetes, 1 = com diabetes)

Atributos: Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction e Age.

Preparação dos dados

- Substituição de zeros inválidos por valores ausentes nas variáveis clínicas.
- Imputação de valores ausentes pela mediana.

- Padronização com StandardScaler.
- Divisão estratificada em treino (80%) e teste (20%).

Métodos de IA utilizados

Parte	Algoritmo	Detalhes
Parte 1	KNN	k-Nearest Neighbors, melhor k = 13
Parte 2	SVM	kernel = linear, C = 1, gamma = scale

Ambos os modelos foram treinados com validação cruzada estratificada (5 folds).


Avaliação dos modelos

Foram utilizadas as métricas: acurácia, precisão, revocação (recall), F1-score e ROC-AUC, além de matrizes de confusão e gráficos comparativos.


Modelo	Acurácia	Precisão	Revocação	F1-score	ROC-AUC
KNN (k=13)	71.4%	60.9%	51.9%	0.56	0.79
SVM (linear)	70.1%	59.1%	48.1%	0.53	0.81

Gráficos de avaliação


Matriz de confusao - KNN




Matriz de confusao - SVM




Busca do melhor k no KNN



Comparacao de metricas



Curvas ROC - KNN vs SVM



Comparação dos resultados

O modelo com melhor desempenho geral foi o KNN, considerando F1-score (0.56 vs 0.53) e acurácia (71.4% vs 70.1%). O SVM apresentou ROC-AUC ligeiramente superior (0.81 vs 0.79), indicando melhor capacidade de separar as classes em termos de ranking de probabilidades.

O KNN obteve melhor revocação, identificando mais casos positivos de diabetes, enquanto o SVM teve precisão e revocação mais equilibradas com kernel linear. A busca de hiperparâmetros mostrou que $k=13$ foi o melhor para o KNN, e $C=1$ com kernel linear foi o melhor para o SVM.

Conclusão

O projeto demonstra o fluxo completo de uma solução de Inteligência Artificial: definição do problema, preparação dos dados, treinamento, avaliação e comparação entre modelos. Os resultados mostram que ambos os algoritmos são capazes de classificar a presença de diabetes com desempenho razoável, com o KNN apresentando leve vantagem nas métricas principais de classificação. As limitações incluem o tamanho reduzido do dataset e o desbalanceamento entre classes, o que impacta a revocação dos modelos. Trabalhos futuros podem explorar outras técnicas de balanceamento e engenharia de atributos.